

APRIL 2025



ITESO, Universidad  
Jesuita de Guadalajara

# Modelo de Crédito Tradicional

Modelos de Crédito | P2025

PRESENTADO POR:

Daniel Sánchez,  
Gustavo de Anda,  
Ana Luisa Espinoza

PRESENTADO A:  
Rodolfo Slay

# Resumen

---

Este proyecto desarrolla un modelo tradicional de credit scoring para préstamos personales, utilizando un scorecard con 10 variables inspiradas en FICO, VantageScore y prácticas bancarias de Estados Unidos. El modelo evalúa solicitantes mediante restricciones de elegibilidad y asigna puntajes basados en historial de pagos, utilización de crédito, ingresos, entre otros. Más adelante se analiza la formación de tasa de interés, desglosando componentes como la tasa base, prima de inflación, prima de riesgo crediticio, prima de liquidez, costos administrativos y margen de ganancia, resultando en una tasa total del 19.1% anual fijo. Este valor refleja el mayor riesgo crediticio y la poca liquidez de los préstamos personales en comparación de otros productos crediticios. Los resultados sugieren un modelo funcional, con oportunidades de mejoras. Se aplicaron 3 modelos de Machine Learning para clasificar personas morosas y se determinó que el modelo óptimo fue Random Forest con accuracy del 93%.

## Introducción

---

Los préstamos personales son productos crediticios no garantizados en gran mayoría, que permiten financiar necesidades de consumo, como imprevistos, gastos médicos, liquidar otras deudas, inversiones, o la adquisición de bienes duraderos. Un préstamo personal permite a un individuo obtener dinero prestado y pagar su adeudo en pagos iguales de manera mensual hasta 7 años, bancos, uniones de crédito y 'online lenders' como LendingClub pueden otorgar préstamos personales. (Bankrate, 2025).

Este proyecto tiene como objetivo desarrollar un modelo tradicional de credit scoring para evaluar la solvencia de solicitantes de préstamos personales, asignando un puntaje que determine su aprobación o rechazo. El modelo se basa prácticas de la industria (FICO, VantageScore) y requisitos de instituciones financieras de Estados Unidos, con el fin de proporcionar una herramienta estructurada y transparente para la toma de decisiones crediticias.

# Selección del Modelo de Crédito



El objetivo del proyecto es construir un modelo de credit scoring que evalúe a los solicitantes de préstamos personales y genere un puntaje o decisión de aceptación o rechazo. Se eligió un scorecard tradicional, un método ampliamente utilizado en la industria financiera para evaluar el riesgo crediticio. Este enfoque asigna un puntaje determinado a variables clave (ingresos, historial crediticio, salario, etc.) dentro de un rango de acuerdo a su ponderación en el modelo. Para obtener un puntaje final, se suman los puntos de cada variable y el puntaje final se compara con un umbral de decisión.

El modelo desarrollado es un scorecard tradicional diseñado específicamente para préstamos personales, diseñado para evaluar la solvencia de los solicitantes y tomar decisiones de aprobación. Los préstamos personales, al ser créditos no garantizados, requieren un análisis cuidadoso de variables financieras y de comportamiento. La selección de variables necesarias en el modelo propuesto están sustentadas en literatura del modelo FICO y en prácticas bancarias estadounidenses. En la siguiente sección se explicará a detalle la ponderación y rango de puntaje de cada variable.

Por otro lado, los modelos de machine learning aplicados a la clasificación crediticia permiten desarrollar sistemas predictivos capaces de identificar patrones complejos y no lineales en grandes volúmenes de datos históricos. Su principal objetivo es estimar la probabilidad de incumplimiento de un solicitante, facilitando una segmentación más precisa del riesgo crediticio. A diferencia de los modelos tradicionales, los algoritmos de machine learning pueden adaptarse a cambios en el comportamiento de los clientes mediante reentrenamiento continuo, mejorando la capacidad de generalización y la toma de decisiones automatizadas. En el presente trabajo se realizarán modelos tradicionales y de Machine Learning para comparar su efectividad en la clasificación.

Las puntuaciones suelen oscilar entre 300 y 850, donde una puntuación más alta indica menor riesgo de impago. Una buena puntuación puede resultar en condiciones favorables (tasas bajas, montos altos), mientras que una puntuación baja conlleva tasas más altas o rechazo. El modelo de puntuación crediticia evalúa diversos factores, como el historial de pagos, la utilización del crédito, la duración del historial crediticio, los tipos de cuentas de crédito y las consultas de crédito recientes.

A cada factor se le asigna una ponderación, y la fórmula del modelo calcula una puntuación crediticia con base en la evaluación. Una puntuación crediticia suele oscilar entre 300 y 850, y una puntuación más alta indica un menor riesgo de impago. Una buena puntuación crediticia puede resultar en condiciones favorables, mientras que una mala puntuación puede conllevar tasas de interés más altas y condiciones menos favorables.

## VARIABLES

---

Las variables seleccionadas para el modelo tradicional son las siguientes:

- **Historial de pagos:**
  - Evalúa si los pagos se realizaron a tiempo.
- **Monto total adeudado:**
  - Saldo total pendiente, como porcentaje del saldo total del crédito.
- **Historial de créditos:**
  - Tiempo desde el primer crédito solicitado.
- **Tipos de líneas de crédito:**
  - Diversidad de cuentas de crédito.
- **Nuevas líneas de crédito:**
  - Consultas recientes en Buró de Crédito.
- **Crédito disponible:**
  - Crédito no utilizado.
- **Utilización del crédito:**
  - Porcentaje de crédito usado.
- **Ingresos mensuales:**
  - Capacidad de pago.
- **Antigüedad laboral:**
  - Estabilidad financiera.
- **Cantidad de préstamos abiertos:**
  - Carga crediticia.

Asimismo para el modelo se determinaron las restricciones de entrada (filtros de elegibilidad) basadas en los requisitos impuestos por bancos o uniones de crédito, según la FED, los pagos mensuales de préstamos personales oscilan entre 147 a 251 USD, por lo que un ingreso mínimo de 400 USD demuestra buena solvencia.

- 1. Edad mínima: 18 años (American Express, 2025)
- 2. Ingresos mensuales mínimos: \$400 USD (Fed, 2025).

MODELO

El primer paso es que el solicitante cumpla con todos los filtros de elegibilidad, de lo contrario se rechazará el crédito antes de calcular el puntaje. Para cada rango de cada variable, el puntaje se muestra entre paréntesis. El desglose de la puntuación de las variables del scorecard se desglosan a continuación:

Tabla 1. Puntuación de Variables del scorecard

Variable	Peso Máximo (Puntos)	Rangos
Repayment History	350	0 atrasos (350), 1 (200), 2 (100), 3+ (0)
Total Amount Owed	150	<1000 USD (150), 1K-5K (100), 5K-10K (75), >10K (50)
Length of Credit History	150	<2 años (50), 2-5 (75), 5-10 (100), >10 (150)
Types of Credit Lines	100	1 tipo (60), 2 (80), 3+ (100)
New Credit Lines	100	0 consultas (100), 1 (80), 2 (60), 3+ (40)
Available Credit	100	>5K USD (100), 2K-5K (80), 1K-2K (60), <1K (40)
Credit Utilization	150	<30% (150), 30-50% (100), 50-70% (75), >70% (50)
Ingresos Mensuales	100	400-700 USD (40), 700-1K (50), 1K-2K (60), 2K-3K (80), >3K (100)
Antigüedad Laboral	100	<1 año (40), 1-3 (60), 3-5 (80), >5 (100)
Cantidad de Préstamos Abiertos	100	0-1 (100), 2-3 (80), 4-5 (60), >5 (40)

El **total máximo** de puntaje es **1,350 puntos** y el **umbral** seleccionado para el modelo es de **600 puntos**. La selección de variables es una combinación de los modelos tradicionales con FICO Score y VantageScore, además de algunos requerimientos que piden los bancos e instituciones financieras en México.

Los pesos se asignaron siguiendo estándares de la industria: el historial de pagos tiene el mayor peso, alineado con FICO (35%). Los rangos se definieron con base en lógica de riesgo: por ejemplo, 0 atrasos otorgan el máximo puntaje (350), mientras que 3 atrasos otorgan 0, reflejando un alto riesgo de default. Las restricciones se basan en requisitos de bancos mexicanos, asegurando que el modelo sea práctico y aplicable.

## RESULTADOS

[GITHUB LINK](#)

Se desarrolló un modelo para determinar si un solicitante de un préstamo personal debe ser aprobado o rechazado. Este modelo toma información básica de cada solicitante, como su edad, ingresos mensuales, historial de pagos y nivel de endeudamiento, y genera un puntaje que representa su riesgo crediticio. Luego compara ese puntaje con un valor límite: si el puntaje es igual o mayor a límite, el solicitante es aprobado; si es menor, es rechazado. Para probar el modelo, se utilizó el dataset "Give Me Some Credit" (Kaggle, 2011), que incluye datos de 150,000 solicitantes. De estos, solo un 6.7% (10,026) incumplió con sus pagos en los últimos 2 años, mientras que el resto, no lo hizo, esto puede indicar un desbalanceo en los datos, que el modelo puede heredar en su funcionamiento de aprobar o rechazar solicitantes.

En una primera etapa, se creó un modelo con 10 variables, sin embargo el dataset no incluía algunas variables necesarias, como el número de consultas recientes en buró de crédito o la antigüedad laboral, por lo que se generaron datos simulados para completarlas. Para completar los valores faltantes del ingreso mensual, se utilizó la mediana. Otras variables fueron mapeadas directamente de los datos disponibles. Al probar este modelo con un umbral de 600 puntos, se encontró que aprobaba a casi todos los solicitantes, incluyendo a solicitantes que incumplieron.

Con el fin de eliminar el ruido de los datos simulados y probar el modelo con datos reales, se simplificó el modelo, dejando solo las variables que podían obtenerse directamente del dataset o que pudieran ser mapeadas.

Esto redujo el modelo a 8 variables, con un puntaje máximo de 1,150. También se ajustaron los rangos y penalizaciones para ser más estrictos con los solicitantes que tienen atrasos en sus pagos, o un nivel alto de endeudamiento, que un análisis inicial mostró que estas variables están más relacionadas con el incumplimiento. Se realizaron pruebas con diferentes umbrales de decisión para aprobar o rechazar a los solicitantes. Con un umbral de 900 puntos, el modelo fue demasiado estricto, aceptando a 62,607 solicitantes, pero rechazando a muchos solicitantes que no incumplieron (47,715), y solo aprobó a 934 que sí incumplieron.

Esto indicó que el umbral podía ser muy alto. Después de analizar como se distribuían los puntajes con un gráfico de múltiples histogramas, se probaron umbrales más bajos. Con un umbral de 800 puntos, el modelo aprobó a más solicitantes que no incumplen (76,747), mientras mantiene un número alto de personas que no incumplieron que fueron rechazados (33,575). Estos resultados reflejan que el modelo puede identificar a los solicitantes de bajo riesgo, pero aún aprueba a algunos de alto riesgo (1,894). Esto puede deberse a que el dataset tiene muchos más solicitantes que no incumplen. lo que hace que el modelo tienda a aprobar más.

Las etiquetas utilizadas para la clasificación en el modelo tradicional y los modelos de Machine Learning son las etiquetas de la variable 'SeriousDlqin2yrs', que muestra el incumplimiento en 90 días o más del crédito, indica con un 0 si el individuo no ha incumplido, y con 1 si incumplió. En el modelo tradicional, esta variable se invierte para poder ejecutar la lógica de decisión para aprobar o rechazar al aplicante, por lo que la interpretación de gráficas y matriz de confusión puede diferir de los modelos de Machine Learning, en donde la variable no es alterada o manipulada.

La descripción para las demás variables del dataset "Give Me Some Credit" se encuentran en el Anexo 10, página 25.

## RESULTADOS DE LA EVALUACIÓN DEL MODELO TRADICIONAL (10 VARIABLES)


En esta primera etapa, el modelo de scorecard fue desarrollado únicamente a partir de la investigación y buenas prácticas encontradas de cómo crear un scorecard. No se utilizó ninguna técnica de Machine Learning, como Logistic Regression, que es el estándar en la industria, para determinar el peso de las variables, ni se aplicaron transformaciones como Weight of Evidence (WoE) o métricas como Information Value (IV) para seleccionar variables o segmentar rangos (Medium, 2020).

### Estadísticas de los Puntajes:

- Solicitantes Elegibles: 143416
- Promedio de Puntaje: 1125.55
- Desviación Estándar: 133.73
- Puntaje Mínimo: 565
- Puntaje Máximo: 1340

### Métricas de Evaluación:

- Accuracy: 0.9190
- Precision: 0.9334
- Recall: 0.9834
- F1-Score: 0.9578
- AUC-ROC: 0.8301




**Figura 2.** Distribución de Puntajes de Crédito: Modelo Tradicional

La mayoría de los solicitantes se concentran en puntajes de 1,100 y 1,300 puntos, con un promedio de puntaje de 1,125,55 puntos. El umbral de aprobación es demasiado bajo comparado con la distribución de los puntajes y el puntaje promedio, esto implica que casi todos los solicitantes están siendo aprobados, incluso aquellos que podrían representar riesgo. La poca cantidad de puntajes cercanos al puntaje mínimo y del umbral indica que el modelo otorga puntajes altos en general.



Este desfase también se manifiesta en las métricas de desempeño del modelo, las cuales presentan valores aparentemente elevados. Sin embargo, la alta precisión (accuracy) puede estar distorsionada por el desbalance en las clases y por un umbral de decisión poco exigente, lo que impide asegurar que los solicitantes aprobados efectivamente no incurran en incumplimiento. El modelo tiende a aprobar a la mayoría de los solicitantes, como lo evidencia el valor elevado del recall, lo cual sugiere una baja selectividad del umbral. Si bien el área bajo la curva ROC (AUC) es razonable, lo que implica una capacidad moderada de discriminación entre buenos y malos pagadores, las métricas generales están sobreestimadas debido a que el modelo no realiza una diferenciación rigurosa entre perfiles de riesgo.


## MATRIZ DE CONFUSIÓN



**Figura 3.** Matriz de Confusión: Modelo Tradicional

La estructura de la matriz de confusión se compone de la siguiente manera (Predicción:Valor Real): 'True Positives' aprobados que no incumplen (Aprobado:Aprobado); 'False Positives' aprobados que incumplieron (Aprobado:No Aprobado); 'False Negatives' rechazados que no incumplen (No Aprobado:Aprobado); y 'True Negatives' rechazados que incumplieron. La matriz está totalmente cargada a favor de aprobar, lo que refuerza la necesidad umbrales más altos para reducir las aprobaciones de alto riesgo.

## CURVA ROC



**Figura 4.** Curva ROC: Modelo Tradicional

La curva ROC del modelo tradicional es aceptable, con área de 0.83. En modelos de crédito, un área debajo de la curva AUC de 0.75 o mayor es el estándar aprobado por la industria y un pre-requisito para la validación del modelo (Mashanovich, 2023). Sin embargo, el rendimiento real podría verse afectado al depurar el ruido de los datos simulados para las variables faltantes en el dataset (consultas en buró, antigüedad laboral), lo cual se realizó en una segunda etapa.

Las métricas atractivas del modelo se explican por un umbral de aprobación muy bajo de 600 puntos, que aprueba a casi todos los solicitantes, esto genera un alto 'recall', pero una baja capacidad real de rechazo de clientes riesgosos.

## RESULTADOS DEL MODELO TRADICIONAL SIMPLIFICADO


Partiendo del modelo tradicional base, se decidió desarrollar una versión simplificada con el propósito que fuera una versión más realista y confiable, eliminando variables no presentes en el dataset o que no se pudieran mapear directamente de los datos reales. La intención es evitar sesgos derivados de los datos simulados, y cambiar el enfoque en evaluar el desempeño del scorecard con los datos del dataset "Give Me Some Credit" (Kaggle, 2011).

Las diferencias principales de este modelo simplificado con respecto del modelo base son que no se utilizan datos simulados, por lo que se eliminan las variables de consultas en buró y antigüedad laboral. Se ajustan los rangos de puntajes, ahora con un puntaje mínimo de 275 puntos a un puntaje máximo de 1,100 puntos, este nuevo rango de puntajes muestra una distribución más amplia. Se prueba el modelo con varios umbrales (800, 850, 900)

**Tabla 2.** Métricas de Evaluación: Modelo Simplificado

<b>Métrica</b>	<b>Umbral 800</b>	<b>Umbral 850</b>	<b>Umbral 900</b>
Accuracy	0.7030	0.6131	0.5892
Precision	0.9796	0.9836	0.9853
Recall	0.6957	0.5946	0.5675
F1-Score	0.8136	0.7411	0.7202
AUC-ROC	0.8290	0.8290	0.8290
Tasa de Falsos Positivos (FPR)	19.74%	13.52%	11.54%
Tasa de Falsos Negativos (FNR)	30.43%	40.54%	43.25%

El umbral de 800 puntos tiene el mejor equilibrio entre aprobación y rechazo, acepta a más clientes buenos, pero también a clientes con riesgo (False Positive Rate), aplicar este umbral puede ser útil si se desea maximizar la inclusión con cierto nivel de tolerancia al riesgo. El umbral de 850 se puede considerar “conservador”, ya que reduce los falsos positivos, pero en proporción aumenta un 10% los falsos negativos, mejora el modelo en su precisión, pero empieza a rechazar muchos solicitantes, es decir sacrifica aceptar a solicitantes ‘aptos’ o ‘confiables’ para reducir pérdidas por incumplimiento. Por último el umbral de 900 es el más estricto, las pruebas muestran que tiene la mayor precisión y menor tasa de falsos positivos, pero sacrifica significativamente el ‘recall’ ya que es el modelo que tiene la menor cantidad de solicitantes aprobados (True Positives), utilizar este umbral solo sería útil si se quiere ser más conservador a la hora de otorgar un préstamo, ya que se buscan puntajes más altos dentro de la distribución.



**Figura 5.** Distribución de Puntajes de Crédito: Modelo Simplificado

## ÁREAS DE MEJORA

Existen varias oportunidades de mejora que pueden fortalecer su aplicabilidad en contextos reales. Se recomienda disponer de datos reales completos, es decir, un set de datos que incluya todas las variables del modelo de preferencia, ya sea el modelo tradicional o el modelo simplificado (Anexo 11). Es importante que estas variables se obtengan directamente del dataset, sin necesidad de mapear o simular información, ya que esto puede introducir ruido y afectar el desempeño del modelo, si se necesitan mapear variables, tratar con cuidado el manejo de datos.

Las variables, puntajes y rangos del modelo asignados fueron definidos a partir de la investigación, sin embargo en la prueba se realizaron ajustes en estos campos, otra área de mejora sería iterar manualmente estos datos con base en el análisis estadístico de los datos de solicitantes o de clientes. Esto permitirá calibrar las variables del scorecard según el contexto operativo.

El área con mayor margen de mejora de este scorecard es la aplicación de técnicas o modelos de Machine Learning, como Logistic Regression que es una técnica ampliamente utilizada en la industria crediticia, implementar ML permitirá comparar el desempeño contra el scorecard original, obtener probabilidad más finas de incumplimiento, mejorar la calibración de la puntuación crediticia. Además se recomienda usar métricas como Weight of Evidence para transformar variables categóricas o continuas e Information Value para seleccionar las variables más informativas en la predicción del incumplimiento. Estas métricas permiten desarrollar un modelo más robusto.

## COMPARACIÓN CON BENCHMARK

El dataset "Give Me Some Credit" es un dataset público proporcionado por Kaggle. En la referencia original del dataset, se invita a que varios desarrolladores o científicos de datos usen los datos para desarrollar sus propios modelos de clasificación. Se encontró un notebook asociado a los datos que utiliza varios modelos de Machine Learning para clasificar los datos. Dentro de este notebook se utilizan tres modelos principales: Logistic Regression, Random Forest y XGB Classifier, siendo este último el que se toma como referencia para la comparación.

El notebook proporciona métricas de evaluación del modelo de XGB Classifier, las cuales se pueden comparar con el modelo tradicional simplificado (Scorecard), que es el que mejor clasifica de los dos modelos desarrollados. Las métricas del modelo XGB Classifier son: Precision: 0.55, Recall: 0.19, F1 Score: 0.29. Por otro lado, las métricas del modelo Scorecard desarrollado, evaluadas en un umbral de 800, son: Accuracy: 0.7030, Precision: 0.9796, Recall: 0.6957, F1 Score: 0.8136 y AUC-ROC: 0.8290.

Al analizar las métricas, se observa que el modelo Scorecard desarrollado supera ampliamente al modelo XGB Classifier en la mayoría de los indicadores. En términos de Precision, el modelo Scorecard alcanza un valor de 0.9796, lo que indica una alta capacidad para identificar correctamente los casos positivos (préstamos riesgosos) sin generar falsos positivos, en comparación con el 0.55 del XGB Classifier. Sin embargo, en Recall, el modelo XGB Classifier tiene un desempeño significativamente más bajo (0.19) frente al 0.6957 del modelo Scorecard, lo que sugiere que el modelo de referencia tiene dificultades para capturar una proporción adecuada de los casos positivos, dejando pasar muchos préstamos riesgosos sin identificar. El F1 Score, que combina Precision y Recall, también refleja esta diferencia: el modelo Scorecard obtiene un 0.8136, mucho más alto que el 0.29 del XGB Classifier, lo que indica un mejor balance entre ambos indicadores. Además, el AUC-ROC del modelo Scorecard (0.8290) demuestra una buena capacidad discriminativa entre clases, aunque este valor no se reporta para el modelo XGB Classifier en el notebook de referencia.

En el modelo Scorecard desarrollado, se invirtió la variable predictora 'SeriousDlqin2yrs' para ajustar su interpretación al contexto del análisis, definiendo los valores de manera que 1 represente la ausencia de morosidad grave y 0 indique su presencia. Esta manipulación no se realizó en el notebook de referencia, donde la variable se mantuvo en su forma original (1 para morosidad grave y 0 para ausencia de morosidad). Esta diferencia en la definición de la variable objetivo altera la interpretación de las métricas de clasificación, como Precision y Recall, ya que los "positivos" y "negativos" tienen significados opuestos en cada modelo, lo que debe considerarse al comparar los resultados.

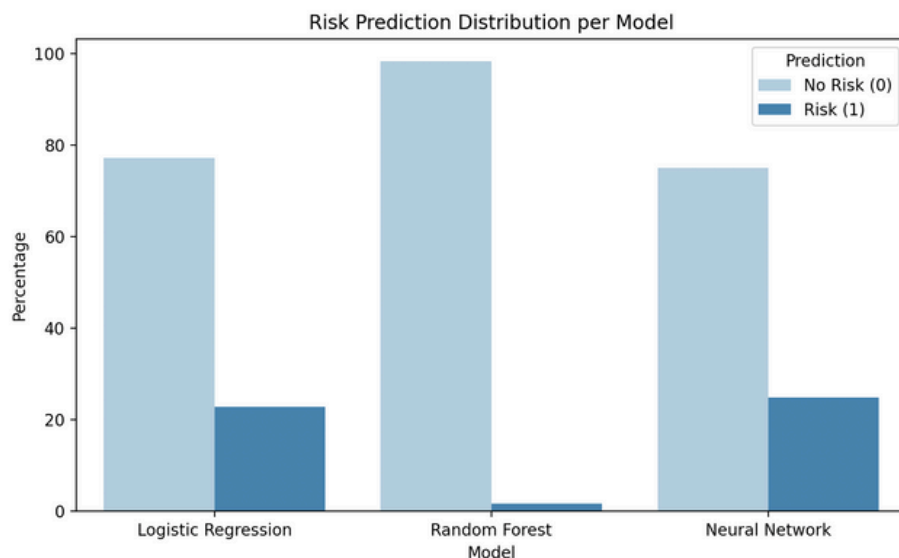
## RESULTADOS PARA MODELOS DE MACHINE LEARNING

Se realizaron tres modelos de Machine Learning para realizar la clasificación crediticia con las categorías: 'risk' y 'no risk' utilizando los modelos de: Logistic Regression, Random Forest y Neural Network. La etiqueta 'risk' clasifica a las personas probables de caer en default, mientras que la etiqueta 'no risk' es para personas con baja probabilidad de default. Los modelos de Logistic Regression y Random Forest se realizaron utilizando la librería Sklearn en python. Por otro lado, la red neuronal se realizó utilizando tensor flow de Keras. En la misma línea, la arquitectura de la red neuronal consta de 3 capas densas:

1. Primera capa oculta: capa densa con 64 neuronas, función de activación **ReLU**
2. Segunda capa oculta: capa densa con 32 neuronas, función de activación **ReLU**
3. Capa de salida: capa densa de 1 neurona con activación **sigmoide** (para clasificación binaria)

La implementación del modelo se desarrolló en Python utilizando programación orientada a objetos (OOP), encapsulando el flujo completo en una clase (CreditRiskMLModel). Esta clase organiza las tareas de preprocesamiento, entrenamiento de los modelos, evaluación, generación de predicciones y visualización, promoviendo modularidad y facilidad de mantenimiento. Para mayor claridad, en el **anexo 8** se muestra el diagrama de flujo lógico del modelo implementado en Python utilizando OOP.

Para seleccionar el mejor modelo de Machine Learning se calculó el AUC-ROC y la matriz de confusión para cada modelo. Primeramente, en la Figura 5 se observan las predicciones de clase obtenidas con cada modelo:



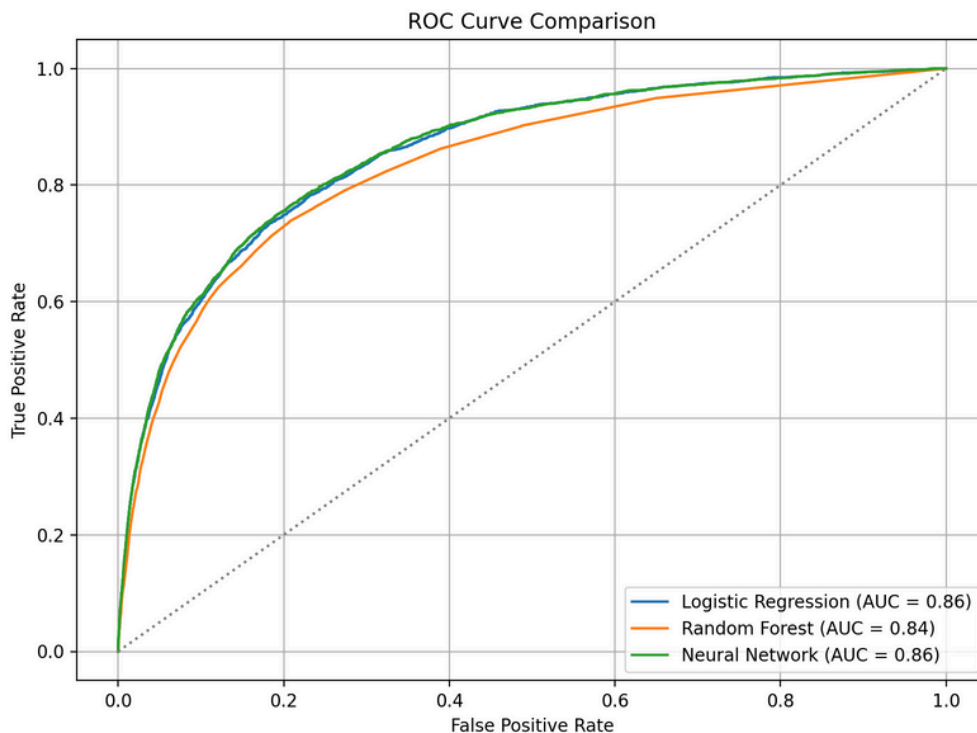
**Figura 6.** Predicciones 'risk' y 'no risk' para modelos de Machine Learning (PD)

La Figura 6 muestra la distribución porcentual de las predicciones de riesgo realizadas por tres modelos de Machine Learning: regresión logística, Random Forest y red neuronal. El dataset utilizado corresponde al año 2011 y contiene información de la población estadounidense. De acuerdo con datos históricos de la Reserva Federal (FED, 2025), la tasa de morosidad en créditos personales en el periodo Q4 2011 era de aproximadamente 3.07%, por lo que un modelo ideal debería identificar como 'risk' a un porcentaje similar al expuesto por la FED. En este sentido, el modelo Random Forest es el que más se aproxima al umbral esperado, clasificando como 'risk' al 1.70% de los individuos.

En esta línea, cabe mencionar que según Trading Economics (2025), el porcentaje de default en créditos personales en 2025 es de 1.62%, quedando alineado con el modelo. Por otro lado, los modelos de regresión logística y red neuronal presentan una clara tendencia a sobreestimar el riesgo, etiquetando como 'risk' al 22.79% y 24.90% de los casos, respectivamente. Este sesgo podría comprometer la eficiencia del modelo al limitar injustificadamente el acceso al crédito para perfiles con baja probabilidad de incumplimiento. Asimismo, el sesgo de estos modelos está limitando el mercado de estos productos, comprometiendo posibles ganancias en mayor proporción a las posibles pérdidas por falsos negativos del modelo. Así, considerando la prevalencia real del fenómeno, Random Forest se posiciona como el modelo más adecuado para esta tarea de clasificación.

<i><b>Métrica</b></i>	<i><b>Logistic Regression</b></i>	<i><b>Random Forest</b></i>	<i><b>Neural Network</b></i>
Accuracy	0.8071	0.9348	0.784
Precision	0.2173	0.5249	0.202
AUC-ROC	0.857	0.8355	0.8592

**Tabla 1.** Métricas de Evaluación: Credit Risk Models



**Figura 7.** Curva AUC - ROC comparando Regresión Log., R.F. y N.N.

La Figura 7 muestra la curva ROC para los modelos de regresión logística, Random Forest y red neuronal, utilizada para evaluar su capacidad de diferenciación. Los modelos de regresión logística y red neuronal presentan un AUC de 0.86, mientras que Random Forest obtiene un AUC de 0.84, todos indicando un buen desempeño en la clasificación.

Si bien los tres modelos muestran rendimientos similares según el AUC, es importante considerar que el modelo de Random Forest predice una proporción de casos 'risk' alineada con la tasa real de morosidad (3.07% en 2011). Con esto se puede inferir que, a pesar de tener un AUC ligeramente inferior, Random Forest es el modelo más adecuado para este problema.



## Random Forest

Después de analizar en conjunto los 3 modelos de Machine Learning, se determinó que Random Forest es el mejor modelo para este problema. Para este modelo se obtuvo la siguiente matriz de confusión:




Figura 8. Matriz de confusión: Random Forest

Como se observa en la Figura 8, la clase 'no risk' corresponde al 0 y la clase 'risk' al 1. Con esto en cuenta, el cuadrante superior izquierdo indica que 40,486 personas que pagaron a tiempo sus créditos se clasificaron correctamente como 'no risk' y 390 personas que cayeron en default se clasificaron adecuadamente como 'risk'. Ahora bien 2,498 casos (5.7% de la población) fueron falsos negativos, significando que se clasificó a personas con alta probabilidad de default como aptas para crédito. Finalmente, el modelo clasificó 353 falsos positivos, estos casos son instancias de personas aptas para crédito, el cual se les sería negado.

A diferencia del modelo de Random Forest, los modelos de regresión logística y red neuronal tienen mayor proporción de falsos positivos (era un no risk clasificado como risk) que negativos, lo cual, en el contexto de aprobación de crédito es mejor. No obstante, a pesar de que estos modelos clasifican mejor la clase 'risk', el porcentaje de falsos negativos es del 18.7% y el 17.6% para redes neuronales y regresión logística, respectivamente (Anexos 1 & 2). Observando esto desde el punto de vista del negocio, con estos modelos se estaría desaprovechando arriba del 15% del mercado, mientras que un 5.7% de población que caerá en default generará pérdidas significativas dependiendo de la exposición de la deuda. Si el objetivo del modelo es ganar mercado el modelo idóneo es Random Forest, mientras que si se busca un enfoque más conservador, la opción ideal sería el modelo de regresión logística.

# Análisis de la tasa de interés

## Componentes principales de la tasa de interés

Las tasas de interés para préstamos personales se construyen sumando varios componentes que reflejan el costo del dinero, los riesgos asociados y los costos operativos del prestamista. A continuación, se identifican los componentes, con valores estimados para la tasa de un crédito personal a 5 años, contextualizado para la población de EE.UU con un riesgo crediticio medio (FICO Score de 680 ).



### Tasa Base

Rendimiento de bono del tesoro a 5 años (YCharts, 2025)



### Prima de Riesgo Crediticio

Riesgo moderado para solicitante promedio



### Prima de Liquidez

Costo de oportunidad de no vender el préstamo



### Costos de Fondeo

Tasa de interés para préstamos interbancarios (Datosmacro, 2025)



### Costos Administrativos

Costos operativos del banco



### Margen de ganancia

Beneficio del banco o prestamista

**TASA TOTAL:**



Ahora bien, cada componente de la tasa tiene un rango dependiendo el contexto económico actual y de riesgo de cada cliente. Existe cierta variación del total de la tasa de acuerdo a los scores crediticios de los clientes, en EE.UU las tasas promedio para créditos personales se encuentran dentro de los siguientes rangos (Haughn, 2025):

FICO score	Average personal loan interest rate
Excellent (720-850)	10.73%-12.50%
Good (690-719)	13.50%-15.50%
Fair (630-689)	17.80%-19.90%
Poor (300-629)	28.50%-32.00%

Figura 9. Referencias de tasa para créditos personales por FICO score

Para este producto se determinó la tasa para un crédito personal a 5 años para un ciudadano estadounidense con score crediticio de 680 puntos, el cual es el promedio más bajo de score en EE.UU para el estado de Mississippi (Haughn, 2025). El desglose de la tasa se explica a continuación:

1. Tasa Base

Como referencia para la tasa base, se investigó la tasa de los bonos del Tesoro a 5 años, la cual, al 4 de abril de 2025, es del **3.72%** (YCHARTS, 2025). Esta tasa, determinada por la Reserva Federal, refleja tanto la política monetaria como la situación económica del país. El rendimiento de los bonos del Tesoro a 5 años ya incorpora las expectativas inflacionarias, por lo que no es necesario añadir una prima adicional por inflación. La prima inflacionaria tiene como objetivo compensar la pérdida de poder adquisitivo del dinero durante el periodo del préstamo. Incluir esta prima garantiza un rendimiento real positivo y protege ante el impacto inflacionario proyectado en la economía estadounidense.

2. Prima de Riesgo Crediticio





Lender	User ratings	Best for...	APR range	Loan terms	Loan amounts
 upgrade	★★★★★ (2,286) User Ratings & Reviews ⓘ	Overall personal loans	7.99% - 35.99% (with discounts)	24 to 84 months	\$1,000 - \$50,000
 LightStream	★★★★☆ (363) User Ratings & Reviews ⓘ	Big loans and no fees	6.49% - 25.29% (with autopay)	Varies	\$5,000 - \$100,000
 Upstart	★★★★★ (17,096) User Ratings & Reviews ⓘ	Bad or no credit	6.70% - 35.99%	36 or 60 months	\$1,000 - \$50,000
 LendingClub	★★★★★ (7,384) User Ratings & Reviews ⓘ	Fast approval	7.90% - 35.99%	24 to 72 months	\$1,000 - \$40,000

Figura 10. Referencias de tasa para créditos personales. Fuente: Lendingtree. 2025.

Observando la Figura 9, en el mercado estadounidense las tasas para créditos personales, en promedio, tienen una tasa mínima de 6.5% y máxima de 36%. Para obtener una referencia, si se le resta la tasa de bonos del tesoro a 10 años (4.0%), obtenemos que el spread crediticio tiene un rango aproximado entre el 2.5% - 32% dependiendo del score crediticio.

Situando la población objetivo de este producto, considerando que el promedio estatal más bajo de FICO score en EE.UU es de 680, un puntaje medio-alto, se situará la prima de riesgo crediticio para crédito personal con un valor de **5.6%** para fines demostrativos.

### 3. Prima de Liquidez

Se añade una prima de liquidez al costo de financiamiento para compensar los riesgos adicionales asociados con préstamos de largo plazo, ya que estos comprometen capital por más tiempo y están expuestos a mayores incertidumbres. De acuerdo con Precisionlender (2025), la prima de liquidez para un plazo de 5 años es del **0.45%**, lo cual refleja el costo adicional que representa mantener liquidez durante ese periodo.

### 4. Costos de Fondeo & Administrativos

Para determinar la tasa de interés, se consideran los costos que asume el prestamista para otorgar el crédito. El costo de fondeo, que representa el precio que la entidad financiera paga por obtener los recursos para prestar, tiene un valor del **4.25%** de acuerdo a la tasa de préstamos interbancarios en EE.UU (Datosmacro, 2025). A este se le suma el costo administrativo, correspondiente a los gastos operativos relacionados con la gestión del préstamo que incluye salarios, proceso de solicitudes y gastos de la entidad. Se tomó como referencia el costo expuesto por el Federal Reserve Bank of Minneapolis (Diette, 2025), que es del **2%**.

### 5. Margen de Utilidad

Finalmente, se incorpora el margen, que constituye la ganancia de la institución financiera y que en este caso es del 1%, tomando como referencia el valor expuesto por la Reserva Federal de Minneapolis. Este valor se ajusta dependiendo la utilidad objetivo de la entidad financiera.

Incluyendo todos los factores previamente mencionados, la tasa de interés para el crédito personal a 5 años en EE.UU, para una persona con un FICO score de 680 puntos es de 19.1%. Comparando la tasa obtenida con los promedios de tasas de créditos personales expuestos por Haughn (2025), se observa que se encuentra dentro del rango promedio para el FICO score, siendo coherente y competitiva para el mercado objetivo.

## REPRESENTACIÓN GRÁFICA DE LOS COMPONENTES

Valores en porcentaje:




Figura 11. Desglose de tasa de interés

# CONCLUSIONES

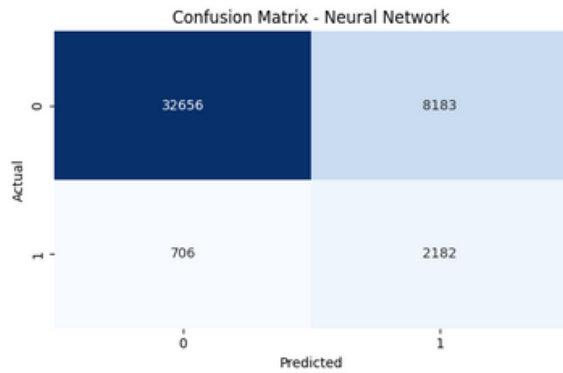
La parte A cumple de manera satisfactoria la creación de un modelo tradicional de crédito scorecard para el producto de préstamos personales, además del desarrollo del modelo en Python, el cual acepta un conjunto de datos, asigna una puntuación crediticia y una decisión de aprobación o rechazo según un umbral de decisión. Además los ajustes realizados refuerzan la precisión del modelo y ajustan penalizaciones para las variables de incumplimiento y se definió un nuevo umbral de decisión. Sin embargo el modelo tiene áreas de mejora, principalmente la incorporación de técnicas de Machine Learning y métricas de preprocesamiento de datos.

Para la parte B, se determinó una tasa de interés del 19.1% incluyendo los factores de riesgo crediticio, inflación y costos generales. Comparando la información disponible sobre entidades financieras en el negocio del crédito, se concluye que la tasa determinada es apropiada para la población objetivo y el producto financiero.


Finalmente, para la Parte C, se concluyó que el modelo más apropiado para clasificar como riesgosas o no riesgosas a caer en default, fue Random Forest con un ROC-AUC de 0.84 y accuracy de 93.48%. La selección del modelo parte del porcentaje clasificado como risk, el cual se alinea a la tasa de morosidad expuesta por la FED para créditos personales. Como ventaja, este modelo predice de forma más alineada a los índices reales. No obstante, como áreas de mejora tiene que subestima el riesgo y clasifica erróneamente a por lo menos a 5.7% de personas morosas. Es importante incluir cierto sesgo o modificar el umbral en estos modelos, ya que en el contexto crediticio puede ser perjudicial un modelo con alto índice de falsos negativos. Comparando los resultados obtenidos con nuestro modelo tradicional con el de Machine Learning, ambos proveen información distinta pero relevante para determinar si se otorga o no un crédito, por lo que lo ideal sería usarlos complementariamente.

El proyecto fue bastante ilustrativo para las aplicaciones de los modelos de crédito existentes junto con sus retos, ventajas y limitaciones. Hay una gran variedad de herramientas que pueden permitir cierta creatividad e innovación para crear nuevos modelos y mejorar los ya existentes para mitigar riesgos y explotar segmentos de mercado no atendidos. Con el proyecto se logró visualizar de forma más integral todos los componentes en el negocio de los créditos, desde determinar una tasa de interés apropiada, investigación de mercado, búsqueda de datasets adecuados a la población objetivo y la implementación de disrupción tecnológica para aprovechar la tecnología de la información y la inteligencia artificial para mejorar aspectos operativos en este sector. Encontramos mayor dificultad en crear desde cero un modelo tradicional para poder justificar y determinar la correcta ponderación de las variables y determinar un umbral apropiado para clasificar las solicitudes.


# Anexos




**Anexos 1.** Matriz de confusión: Neural Network




**Anexo 2.** Matriz de confusión: Logistic Regression




**Anexos 3.** Matriz de confusión: Modelo Tradicional



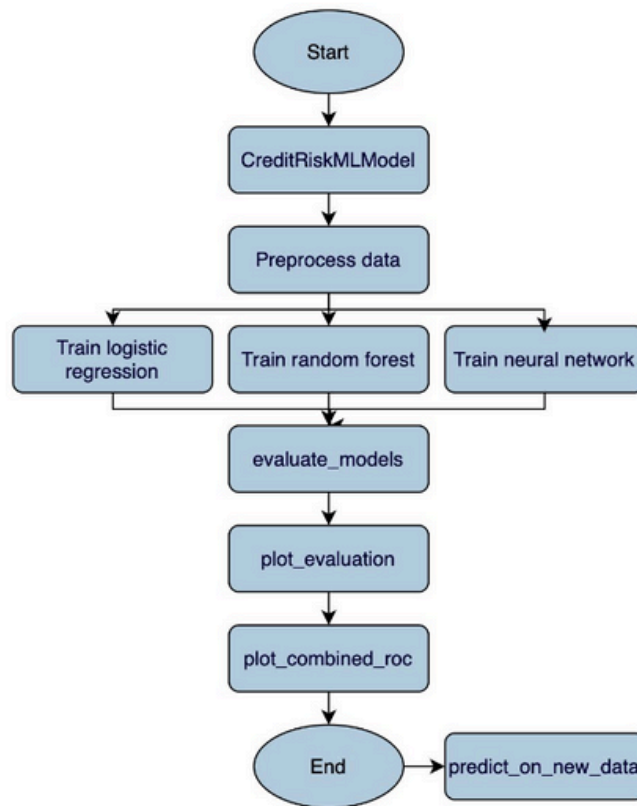
**Anexos 4.** Distribución de Puntajes: Modelo Simplificado



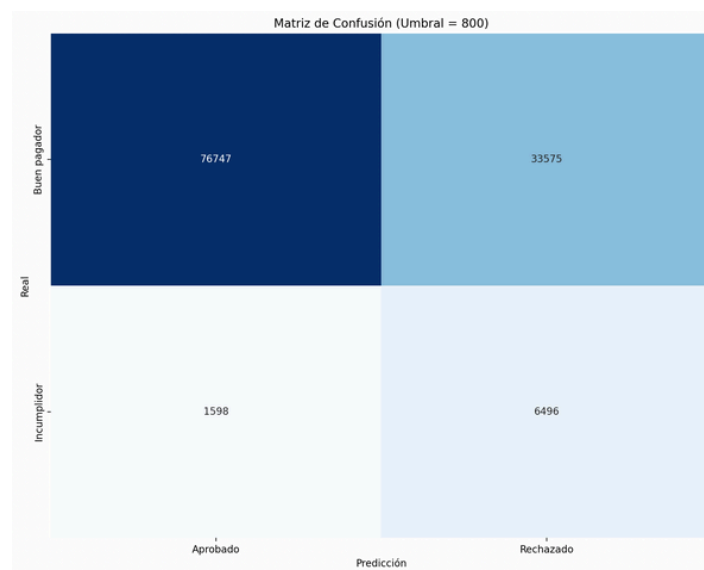
**Anexos 5.** Matriz de confusión: Modelo Simplificado



**Anexos 6.** Matriz de confusión: Modelo Simplificado



**Anexos 8.** Diagrama de flujo Credit risk models (OOP) “Part C”



**Anexos 9.** Matriz de confusión: Modelo Simplificado

Variable Name	Description	Type
SeriousDlqin2yrs	Person experienced 90 days past due delinquency or worse	Y/N
RevolvingUtilizationOfUnsecuredLines	Total balance on credit cards and personal lines of credit except real estate and no installment debt like car loans divided by the sum of credit limits	percentage
age	Age of borrower in years	integer
NumberOfTime30-59DaysPastDueNotWorse	Number of times borrower has been 30-59 days past due but no worse in the last 2 years.	integer
DebtRatio	Monthly debt payments, alimony, living costs divided by monthly gross income	percentage
MonthlyIncome	Monthly income	real
NumberOfOpenCreditLinesAndLoans	Number of Open loans (installment like car loan or mortgage) and Lines of credit (e.g. credit cards)	integer
NumberOfTimes90DaysLate	Number of times borrower has been 90 days or more past due.	integer
NumberRealEstateLoansOrLines	Number of mortgage and real estate loans including home equity lines of credit	integer
NumberOfTime60-89DaysPastDueNotWorse	Number of times borrower has been 60-89 days past due but no worse in the last 2 years.	integer
NumberOfDependents	Number of dependents in family excluding themselves (spouse, children etc.)	integer

**Anexos 10.** Tabla de las variables de dataset "Give Me Some Credit!"

<i>Variable</i>	<i>Peso Máximo (Puntos)</i>	<i>Rangos</i>
Repayment History	350	0 atrasos (350), 1 (150), 2 (50), 3+ (0)
Total Amount Owed	150	<1000 USD (150), 1K-5K (100), 5K-10K (75), >10K (50)
Length of Credit History	150	<2 años (50), 2-5 (75), 5-10 (100), >10 (150)
Types of Credit Lines	100	1 tipo (60), 2 (80), 3+ (100)
Available Credit	100	>5K USD (100), 2K-5K (80), 1K-2K (60), <1K (40)
Credit Utilization	150	<30% (150), 30-50% (50), 50-70% (10), >70% (0)
Ingresos Mensuales	50	400-700 USD (10), 700-1K (20), 1K-2K (30), 2K-3K (40), >3K (50)
Cantidad de Préstamos Abiertos	100	0-1 (100), 2-3 (80), 4-5 (60), >5 (40)

**Anexos 11.** Tabla de las variables del Modelo Tradicional Simplificado



# Referencias

Delinquency Rate on Consumer Loans, All Commercial Banks. (2025, 18 febrero). <https://fred.stlouisfed.org/series/DRCLACBS>

5-Year breakeven inflation rate. (2025, 4 abril). <https://fred.stlouisfed.org/series/T5YIE>

5 Year Treasury Rate Market Daily Trends: Daily Treasury yield curve rates | YCharts. (s. f.). YCharts. [https://ycharts.com/indicators/5\\_year\\_treasury\\_rate](https://ycharts.com/indicators/5_year_treasury_rate)

Haughn, R. (2025, 12 febrero). Average credit score for personal loans. Bankrate. <https://www.bankrate.com/loans/personal-loans/average-credit-score-for-personal-loans/>

Precisionlender Liquidity Curve. (2025). Q2 Company. <https://support.precisionlender.com/hc/en-us/articles/225423608-Precisionlender-Liquidity-Curve>

How do lenders set interest rates on loans? | Federal Reserve Bank of Minneapolis. (s. f.). <https://www.minneapolisfed.org/article/2000/how-do-lenders-set-interest-rates-on-loans>

Tipos de interés de los bancos centrales 2025. (s. f.). Datosmacro.com. <https://datosmacro.expansion.com/tipo-interes>

Diette, M.D. (2025). How do lenders set interest rates on loans? | Federal Reserve Bank of Minneapolis. <https://www.minneapolisfed.org/article/2000/how-do-lenders-set-interest-rates-on-loans>